Prepoznavanje jezika govora iz video-snimka usana korišćenjem klasičnih ML algoritama

Nikola Bakić, EE58/2022, bakicnikola25@gmail.com
Milena Luković, EE19/2022, milenalukovic03@gmail.com

I. Uvod

Razvoj savremenih sistema za obradu multimedijalnih podataka omogućio je analizu govora ne samo na osnovu audio signala, već i na osnovu vizuelnih informacija kao što je pokret usana.

Različiti jezici karakterišu se specifičnim obrascima artikulacije, dinamikom pokreta usana i ritmom govora. Analizom ovih vizuelnih karakteristika moguće je izdvojiti informaciju o jeziku koji se govori. U ovom radu razmatra se problem binarne klasifikacije jezika govora na osnovu video-snimaka usana, pri čemu se razlikuju srpski i engleski jezik.

Razvoj ovakvog modela mašinskog učenja ima značaj u situacijama gde audio signal nije dostupan ili je narušen, kao i u sistemima za asistivne tehnologije i bezbednosne aplikacije.

II. Baza podataka

Korišćeni skup podataka sastoji se od video-snimaka usana govornika, namenjenih za zadatak prepoznavanja jezika govora na osnovu vizuelnih informacija. Svaki video-snimak predstavlja jedan uzorak u skupu podataka, dok je ciljna promenljiva jezik govora: srpski (klasa 0) i engleski (klasa 1).

Ukupan broj uzoraka u bazi iznosi 4.709. Video-snimci su organizovani po direktorijumima, pri čemu svaki odgovara jednom od 30 govornika. Klase su skoro savršeno balansirane (Sl. 1.) — test skup sadrži 400 srpskih i 398 engleskih uzoraka (odnos 50/50).Ova informacija bila je značajna za izbor odgovarajućih klasifikatora i procenu njihove primene. Sva obeležja su numeričkog tipa, u bazi nema kategoričkih obeležja, dok ciljna promenljiva (SR/EN) predstavlja kategoričku izlaznu labelu.

Ulazni podaci u originalnom obliku predstavljaju video-zapise različitog trajanja i broja frejmova, pri čemu svaki snimak sadrži isključivo oblast usana (region of interest). Zbog toga što algoritmi mašinskog učenja zahtevaju numeričke ulaze fiksne dimenzije, izvršena je ekstrakcija i agregacija obeležja, čime je svaki video predstavljen jednim vektorom obeležja.

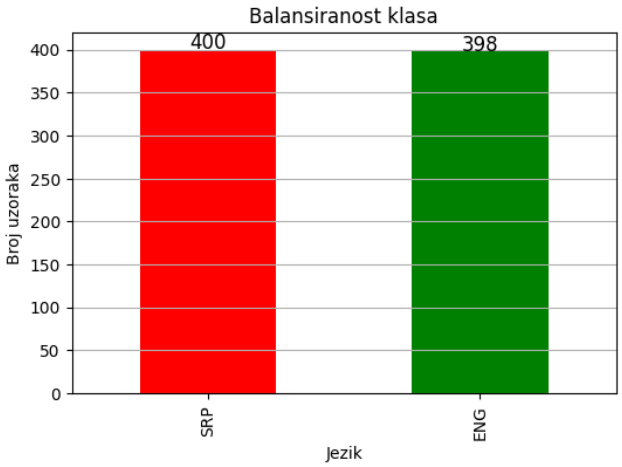

Sl.1. Raspodela uzoraka po klasama.

III. Ekstrakcija i obrada obeležja

Obeležja su izdvojena na osnovu vizuelnih informacija iz video-snimaka usana, bez korišćenja audio signala.

Za svaki video izvršena je analiza pojedinačnih frejmova (svaki drugi, maksimalno 150), pri čemu su izdvojene dve vrste obeležja: geometrijska i teksturalna obeležja.

Geometrijska obeležja dobijena su analizom kontura usana. Nakon konverzije frejma u sivu sliku i binarizacije, izdvojena je kontura koja odgovara oblasti usana, na osnovu koje su određeni parametri kao što su širina usta, visina usta, odnos širine i visine, kao i površina oblasti usana. Na osnovu vremenskog niza ovih vrednosti izračunate su i dinamičke mere: srednje vrednosti i standardne devijacije prvog i drugog diferencijalnog signala, broj vrhova (peaks), stopa govora, opseg otvaranja, srednja vrednost, standardna devijacija i udeo frejmova iznad srednje vrednosti.

Pored geometrijskih, korišćena su i teksturalna obeležja dobijena primenom HOG (engl. Histogram of Oriented Gradients) deskriptora na svakom frejmu (12 orijentacija, 8×8 piksela po ćeliji, blokovi 3×3, L2-Hys normalizacija, ROI 96×96 piksela). HOG obeležja omogućavaju opis lokalnih promena intenziteta i strukture slike, čime se dodatno obuhvataju detalji pokreta i oblika usana kao što su ivice usana i senke.

Kako bi se uzele u obzir i vremenske promene, izračunate su razlike HOG obeležja između uzastopnih frejmova, čime se modeluje dinamika pokreta usana tokom govora, što daje brzinu promene, pravac pokreta i ritam

govora.

S obzirom na to da video-snimci imaju različito trajanje, izvršena je agregacija obeležja na nivou celog snimka: srednja vrednost, standardna devijacija i maksimum HOG vektora, te srednja vrednost i standardna devijacija geometrijskih obeležja. Time je svaki video opisan jedinstvenim vektorom od 54.018 numeričkih obeležja pre redukcije dimenzionalnosti. Proverom je potvrdjeno da nema NaN vrednosti ni u jednom uzorku.

Obeležja uzimaju vrednosti iz različitih opsega, samim tim neka mogu imati velike, a neka male vrednosti. To se sprečava standardizacijom koja je izvršena korišćenjem StandardScaler metode, čime su obeležja transformisana tako da imaju srednju vrednost 0 i standardnu devijaciju 1.

Veliki broj obeležja (posebno onih dobijenih HOG deskriptorom) doprinosi povećanju složenosti sistema. U cilju rešavanja ovog problema primenjena je metoda glavnih komponenti (PCA – Principal Component Analysis). PCA predstavlja metodu nenadgledanog učenja čiji je cilj transformacija uzoraka iz visokodimenzionalnog prostora u prostor niže dimenzionalnosti, uz očuvanje varijanse sadržane u podacima. Testirane su vrednosti broja komponenti iz skupa {80, 120, 150, 200, 300} kako bi se pronašao optimalan odnos između kompleksnosti modela i performansi. U ovom slučaju korišćen je parametar n_components=120, što znači da će broj obeležja biti redukovan sa 54.018 na 120 što je omogućilo optimizaciju procesa obuke modela.

Podela na trening i test skup izvršena je po principu speaker-independent evaluacije: test skup čine isključivo snimci govornika koji nisu bili prisutni u trening skupu, pri čemu je trening skup korišćen za obučavanje modela, dok je test skup izdvojen isključivo za evaluaciju performansi. Konkretno, govornici spk04, spk08, spk14, spk26 i spk28 su izdvojeni kao test skup, dok je preostalih 25 govornika korišćeno za treniranje. Proverom je potvrdjeno da nema preklapanja između skupova, čime je sprečeno curenje informacija.

Ovakav pristup je metodološki ispravniji od nasumične podele po procentima, jer model mora da generalizuje na nevidjene govornike — što odgovara realnom scenariju primene. Test skup sadrži 798 uzoraka (400 srpskih, 398 engleskih), što potvrđuje visoku balansiranost klasa.

IV. KLASIFIKATORI

Primenjena su tri algoritma mašinskog učenja sa ciljem dodele klase na osnovu izdvojenih obeležja. Za svaki je izvršena pretraga hiperparametara (grid search) u kombinaciji sa različitim vrednostima PCA komponenti.

A. Mašina na bazi vektora nosača (SVM)

Mašina na bazi vektora nosača (engl. Support Vector Machine- SVM) je algoritam mašinskog učenja koji rešava problem binarne klasifikacije pronalaženjem ravni koja razdvaja podatke u prostoru obeležja. Osnovna ideja ovog pristupa bazira se na klasifikatoru maksimalne margine čiji je cilj da odredi hiperravan koja će na optimalan način podeliti prostor na dva dela tako da se u jednom delu nađu uzorci iz jedne klase, a u drugom delu uzorci iz druge za linearno razdvojive uzorke.

Klasifikator je korišćen sa „rbf“ kernelom, pri čemu je parametar regularizacije C podešavan kroz vrednosti [0.5, 1, 5, 10],a za gamma je korišćena vrednost „scale“. Optimalna kombinacija je PCA = 120, C = 0.5, što je dalo tačnost od 0.6541 na test skupu (makro F1 = 0.65).

B. Višeslojni perceptron (MLP)

Višeslojni perceptron (engl. Multi-Layer Perceptron – MLP) predstavlja neuronsku mrežu sa propagacijom unapred, koja se sastoji od ulaznog sloja, jednog ili više skrivenih slojeva i izlaznog sloja. Svaki neuron računa linearnu kombinaciju ulaza i primenjuje nelinearnu aktivacionu funkciju, čime se omogućava modelovanje složenih, nelinearnih odnosa u podacima .

Za razliku od linearnih modela, MLP može da nauči kompleksne granice odlučivanja kombinovanjem više neurona i slojeva.

U radu su testirane različite arhitekture mreže što podrazumeva različit broj slojeva i neurona [(128, 64), (256,128), (256, 128, 64), (512, 256, 128)], kao i različite vrednosti stope učenja [0.001, 0.0005]. Broj iteracija je uzimao vrednosti 400 i 600. Konfiguracija koja daje najbolje performanse na test skupu dobija se kombinacijom sledećih parametara: PCA = 150, arhitektura (256, 128), 400 iteracija, ReLU aktivaciona funkcija, Adam optimizacioni algoritam i početna stopa učenja 0.001, sa tačnošću 0.6303 (makro F1 = 0.62).

C. Random Forest

Slučajna šuma (engl. Random Forest) predstavlja ansambl metodu koja se sastoji od većeg broja stabala odluke. Svako stablo se trenira na različitom podskupu podataka, dok se u svakom čvoru razmatra slučajan podskup obeležja, čime se smanjuje međusobna zavisnost stabala i povećava raznovrsnost modela.

Konačna odluka donosi se na osnovu većinskog glasanja svih stabala. Ovakav pristup omogućava smanjenje varijanse modela i smanjuje verovatnoću pojave natprilagođavanja.U okviru ovog rada ispitivane su različite vrednosti broja stabala [100, 300, 500] i dubine stabla [10, 20, bez ograničenja], i broj obeležja po čvoru [sqrt, log2]. Optimalna konfiguracija je PCA = 120, 500 stabala, neograničena dubina, sqrt obeležja, sa tačnošću 0.6153 (makro F1 = 0.61).

V. REZULTATI I ANALIZA

Performanse modela evaluirane su na test skupu koji sadrži uzorke govornika koji nisu korišćeni tokom treniranja. Kao osnovna mera uspešnosti korišćena je tačnost (accuracy), dok su dodatno analizirani i rezultati pomoću matrice konfuzije

SVM je postigao tačnost od 65,41% (makro F1 = 0,65), što ga čini najboljim modelom u ovom istraživanju (Sl. 2.).

Matrica konfuzije pokazuje blagu asimetriju — srpski je prepoznat sa višom preciznošću ali nižim odzivom u odnosu na engleski, što ukazuje na to da model nešto češće pogrešno klasifikuje srpske uzorke kao engleski nego obrnuto.

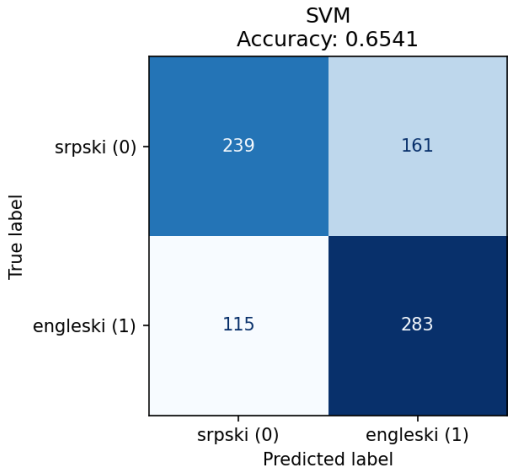

Sl. 2. Matrica konfuzije optimalnog modela (SVM).

MLP (Sl. 3.) je ostvario tačnost od 63,03% (makro F1 = 0,62) i pokazao sposobnost da modeluje složenije odnose u podacima, ali je njegova uspešnost zavisila od izbora hiperparametara i arhitekture mreže. U nekim slučajevima primećeno je natprilagođenje (overfitting), naročito kod većeg broja neuronaAnaliza po klasama otkriva izraženiju asimetriju: odziv za srpski iznosi svega 48%, dok engleski postiže odziv od 78%. Ovo sugeriše da je model razvio tendenciju ka predikciji engleske klase, što je karakteristično za situacije u kojima kapacitet mreže nije optimalno usklađen sa količinom i prirodom dostupnih podataka.

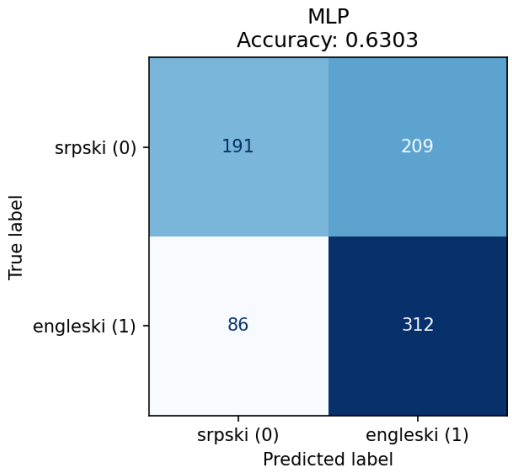

Sl. 3. Matrica konfuzije MLP modela.

Random Forest (Sl. 4.) je ostvario tačnost od 61,53% (makro F1 = 0,61). Uprkos najnižoj ukupnoj tačnosti, ovaj model pokazuje najujednačeniju raspodelu grešaka između klasa, što ukazuje na veću robusnost i manju pristranost u poređenju sa MLP.

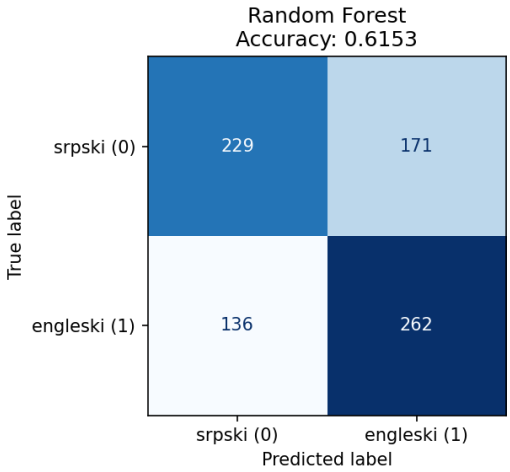

Sl. 4. Matrica konfuzije Random Forest modela.

Razlike u tačnosti između sva tri modela (Sl. 5.) relativno su male (svega 3–4 procentna poena), što ukazuje na to da je primarni faktor koji ograničava performanse reprezentativnost samih obeležja, a ne izbor klasifikatora. Sve tačnosti su iznad nasumičnog nivoa od 50%, ali i znatno ispod granice praktične primenljivosti.

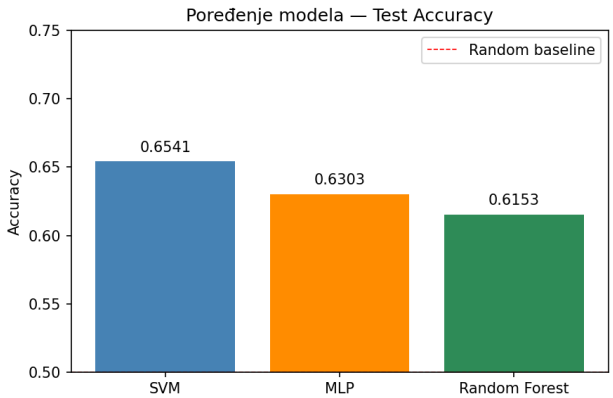

Sl. 5. Grafički prikaz mera uspešnosti finalnih modela

VI. Zaključak

U ovom radu pokazano je da je vizuelna klasifikacija jezika govora moguća i bez audio komponente — sva tri testirana modela nadmašuju nasumično pogađanje od 50%, pri čemu je SVM ostvario najbolji rezultat od 65,41%. Eksperimenti sprovedeni u striktnom speaker-independent protokolu potvrđuju da dobijeni rezultati odražavaju stvarnu sposobnost generalizacije, a ne artificijalne efekte curenja informacija.

Ipak, uočeni su i određeni izazovi, pre svega u vidu sličnosti artikulacionih obrazaca između jezika, kao i varijabilnosti među govornicima. Ovi faktori mogu dovesti do grešaka u klasifikaciji i ukazuju na potrebu za dodatnim unapređenjem modela. Takođe je primećeno da kvalitet snimka i ugao kamere mogu uticati na performanse modela, što dodatno otežava zadatak klasifikacije.